PRÁCTICA OBLIGATORIA EVALUABLE

CLUSTERING DE NOTICIAS

Objetivo

El objetivo es poner en práctica diferentes conceptos aprendidos durante el curso y relacionados con la Recuperación de Información y el procesamiento de texto con la librería NLTK de Python (o Spacy si se prefiere), aplicándolos a una tarea real concreta.

Normativa de entrega

La entrega de esta práctica es *obligatoria* y puede realizarse ***individualmente o por parejas***. A continuación, se detallan otros datos de interés relacionados con la normativa de entrega:

- La fecha límite de entrega de la práctica será el día **2 *de abril de 2018*.**
- La entrega de la práctica se hará a través de Aula Virtual, empleando el **formulario** habilitado para ello (se habilitará más adelante, se pondrá una noticia en el foro de novedades cuando esté disponible).
- Se deberá subir un único archivo comprimido con todo el código fuente que se haya implementado y se necesite para ejecutar la práctica, así como una memoria explicando qué se ha hecho y por qué.

Enunciado

De toda la cantidad de información nueva disponible cada día en la Red, una buena parte se corresponde con noticias. Las noticias en Internet son una importante fuente de información, ya que permiten estar informados en cualquier momento y en cualquier lugar sin fronteras geográficas. Además, debido al fenómeno de la globalización, existe un interés mayor por conocer no sólo las noticias a nivel local o nacional, sino también a nivel internacional, por lo que cada día se consultan noticias escritas en otras lenguas directamente en los propios medios extranjeros. Así, los periódicos online y los portales de noticias se han convertido en una de las principales fuentes de información de actualidad.

Las noticias suelen relatar un hecho que tiene relevancia social, por lo que se trata de textos de actualidad (política, económica, deportiva, etc.), que no suelen ser muy extensos (depende de la temática de la noticia y del contexto actual de esa temática), con una temporalidad muy marcada y una estructura similar (por lo general título, sumario y cuerpo). Estas características influyen de manera directa en la forma de procesarlas, y de ellas se nutren los trabajos que se dedican a investigar diferentes formas de procesar los documentos de noticias para llevar a cabo

distintas tareas. Con las noticias se realizan, entre otras tareas, detección y seguimiento de eventos o sucesos; análisis de sentimientos y opiniones con respecto a mercados financieros, compañías, personas, etc.; generación de resúmenes; clasificación de noticias; predicción de los mercados mediante el análisis de noticias financieras, etc.

Una organización automática de las noticias donde éstas se agrupen por temática puede resultar de interés, ya que facilita el seguimiento de noticias de un tema determinado, evitando así el importante esfuerzo humano requerido para ello. El agrupamiento automático es un proceso de aprendizaje no supervisado cuyo fin es organizar una colección de objetos en diferentes grupos o clusters, de tal manera que los objetos del mismo cluster sean lo más similares posibles entre sí, manteniendo a su vez el menor grado de similitud posible en relación a los objetos pertenecientes a otros clusters.

En esta práctica se pide agrupar de forma automática noticias en base al tema o evento que describen. Además, las noticias pertenecen a diferentes fuentes y en dos idiomas distintos. Los pasos mínimos a dar serían los siguientes:

1. Recopilación de noticias de diferentes fuentes mediante crawling.
2. Procesar los documentos descargados y convertirlos en texto. Habitualmente serán páginas web en formato HTML, por lo que mediante alguna librería se procesarán y se convertirán en texto. Se recomienda BeautifulSoup para ello.
3. Procesar el texto para generar una representación común de cada documento, por ejemplo, una representación vectorial donde cada vector representa un documento. Cada componente del vector representa un rasgo del vocabulario del problema (todos aquellos rasgos únicos de todos los documentos que intervienen en el problema) y tiene un peso concreto, que mide la importancia de ese rasgo en el documento.
4. A partir de una matriz de vectores de documentos se utilizaría un algoritmo de clustering que agruparía los documentos en grupos en base a la similitud de sus contenidos.
   En este problema cada grupo representa una temática diferente.

En esta práctica hay pasos del esquema anterior que no se deben llevar a cabo porque ya se dan hechos:

- Como colección de trabajo se dispone de varios documentos .html obtenidos de diferentes fuentes de noticias online, en inglés y español. Se trata de una colección pequeña, en total 22 documentos.

- Se proporciona un código fuente en Python (con la versión de Python 3.5) con un ejemplo completo de procesamiento de las páginas web en formato txt y agrupamiento mediante un algoritmo de clustering aglomerativo. En este caso se ha utilizado la librería de Machine Learning en Python *Scikit-Learn* (http://scikit-learn.org/stable/). Esta librería presenta diferentes algoritmos para análisis de datos y procesamiento de textos, y es muy común utilizarla junto con NLTK.

En la Figura 1 se presenta una de las funciones principales del código fuente que se proporciona.

```
def cluster_texts(texts, clustersNumber, distance):
    #Load the list of texts into a TextCollection object.
    collection = nltk.TextCollection(texts)
    print("Created a collection of", len(collection), "terms.")

    #get a list of unique terms
    unique_terms = list(set(collection))
    print("Unique terms found: ", len(unique_terms))

    ### And here we actually call the function and create our array of vectors.
    vectors = [numpy.array(TF(f,unique_terms, collection)) for f in texts]
    print("Vectors created.")

    # initialize the clusterer
    #clusterer = GAAClusterer(clustersNumber)
    #clusters = clusterer.cluster(vectors, True)
    clusterer = AgglomerativeClustering(n_clusters=clustersNumber,
                                        linkage="average", affinity=distanceFunction)
    clusters = clusterer.fit_predict(vectors)

    return clusters
```

Figura 1. Agrupamiento de textos con un algoritmo de clustering aglomerativo.

Como se puede ver en la figura, de forma general el código lo que hace es un procesamiento muy básico del texto:

1) Mira cuáles son el conjunto de términos que aparecen en los textos de la colección, para así obtener el vocabulario con el que representar los documentos.
2) Representa cada documento mediante un vector donde cada término del vocabulario se pesa con la medida TF (frecuencia del término en el documento).
3) Agrupa con el algoritmo de clustering, al que le da como parámetros de entrada el número de grupos en los que tiene que agrupar los documentos (en la colección de trabajo las temáticas diferentes son cinco), el tipo de enlace (esto es particular del algoritmo de clustering utilizado) y la medida de similitud con la que comparar los vectores de los documentos.

En la Figura 2 se presenta la salida del código proporcionado. Como se puede ver la salida se corresponde con una lista de números (etiquetas), donde cada número representa uno de los clusters generados. Así, cada posición de la lista se corresponde con uno de los documentos de entrada (respetando el mismo orden en el que estaban en la lista de textos de entrada), de manera que aquellas posiciones de la lista con igual número se refieren a documentos que se han agrupado juntos.

```
C:\Anaconda\envs\Python3Env\python.exe C:/Users/Soto/MI_TRABAJO/DOCENCIA/URJC/MasterD
Prepared  22  documents...
They can be accessed using texts[0] - texts[21]
Created a collection of 18579 terms.
Unique terms found:  4942
Vectors created.
test:  [0 3 0 2 0 0 0 0 2 2 0 0 0 2 0 0 2 4 0 1 0 2]
reference:  [0, 5, 0, 0, 0, 2, 2, 2, 3, 5, 5, 5, 5, 5, 4, 4, 4, 4, 3, 0, 2, 5]
rand_score:  -0.033755274261603394

Process finished with exit code 0
```

Figura 2. Resultado de la ejecución del código de partida.

¿Qué se pide con la realización de esta práctica?

Si se analiza el código proporcionado detenidamente se podrá comprobar que el procesamiento que se ha hecho de los textos de las páginas web de las noticias es muy simple. Por ejemplo, no se están eliminando palabras vacías, no se está haciendo stemming ni lematización, no se reconocen Entidades Nombradas, etc. Esto no es lo habitual en este tipo de problemas. Por lo tanto, lo que debe hacer el alumno es una labor de investigación, de forma que vaya modificando el código, añadiendo nuevo procesamiento con el objetivo de generar la representación de los documentos más adecuada para el problema que se quiere resolver.

Con la métrica empleada para evaluar el resultado de clustering (*Adjusted Rand Index, ARI*[1]*)* se podrá ver si cada modificación que se haga mejora o empeora los resultados obtenidos.

En los trabajos de investigación dedicados a la tarea de clustering de noticias se han utilizado diferentes enfoques, utilizando datos de entrenamiento o no, utilizando diferentes algoritmos, etc. En esta práctica no se utilizarán datos de entrenamiento y el algoritmo de clustering puede ser el propuesto en el código de partida sin necesidad de cambiar a otro. Con respecto a cómo representan las páginas web los diferentes trabajos de investigación sobre esta tarea, también hay mucha variedad: algunos sólo utilizan Entidades Nombradas, o bien las utilizan de forma diferenciada, o utilizan n-gramas, o sólo utilizan parte del documento teniendo en cuenta la estructura de las noticias, etc.

El objetivo de la práctica no es generar una representación de los documentos muy compleja, sino hacer cambios sobre el código proporcionado con cierto criterio, con el fin de mejorar los resultados de agrupamiento. Para ello se tendrá que investigar un poco acerca de esta tarea de clustering de noticias para ver qué se suele hacer, investigar un poco el contenido de las páginas web para tratar de ver qué puede ser más importante a la hora de representar las páginas y también investigar cómo utilizar la librería NLTK para hacer las modificaciones necesarias en la representación de los documentos.

Es importante tener en cuenta que a veces un cambio puede no resultar mejor, pero acompañado de otro cambio adicional sí puede producir mejoras.

Por último, además de modificar y extender el código que se proporciona, **se deben explicar qué cambios se han introducido y por qué**. Es muy importante que se vayan describiendo los diferentes cambios realizados, junto con un análisis de si funciona mejor o peor y **las razones por las que se cree que ocurre**. Hay que justificar cada paso que se dé y analizar si ha llevado a mejoras o no y porqué puede ser.

Pistas

1. **Entidades Nombradas**

   El estilo de redacción de las noticias se corresponde con el género informativo, donde lo primordial es informar. Los elementos que debe reunir una noticia se conocen en el argot

---

[1] https://en.wikipedia.org/wiki/Rand_index

periodístico con el nombre de las 6W" (What, Who, When, Where, Why, How): ¿Qué sucedió?

¿A quién le sucedió? ¿Cuándo sucedió? ¿Dónde sucedió? ¿Por qué sucedió? y ¿Cómo sucedió? Estos seis elementos no son necesarios en todas las noticias, algunos de ellos pueden faltar o se pueden unir. El orden en el que aparecerán las respuestas a estas preguntas dependerá del suceso que se relate, del redactor, o incluso de la guía de estilo del medio que publique la noticia. Las respuestas a las diferentes preguntas que se pueden plantear ante una noticia están presentes en el contenido de la misma y varias de esas respuestas las pueden proporcionar las Entidades Nombradas, como se puede apreciar en la Figura 3, donde están resaltadas con diferentes colores las ENs de distinta categoría.

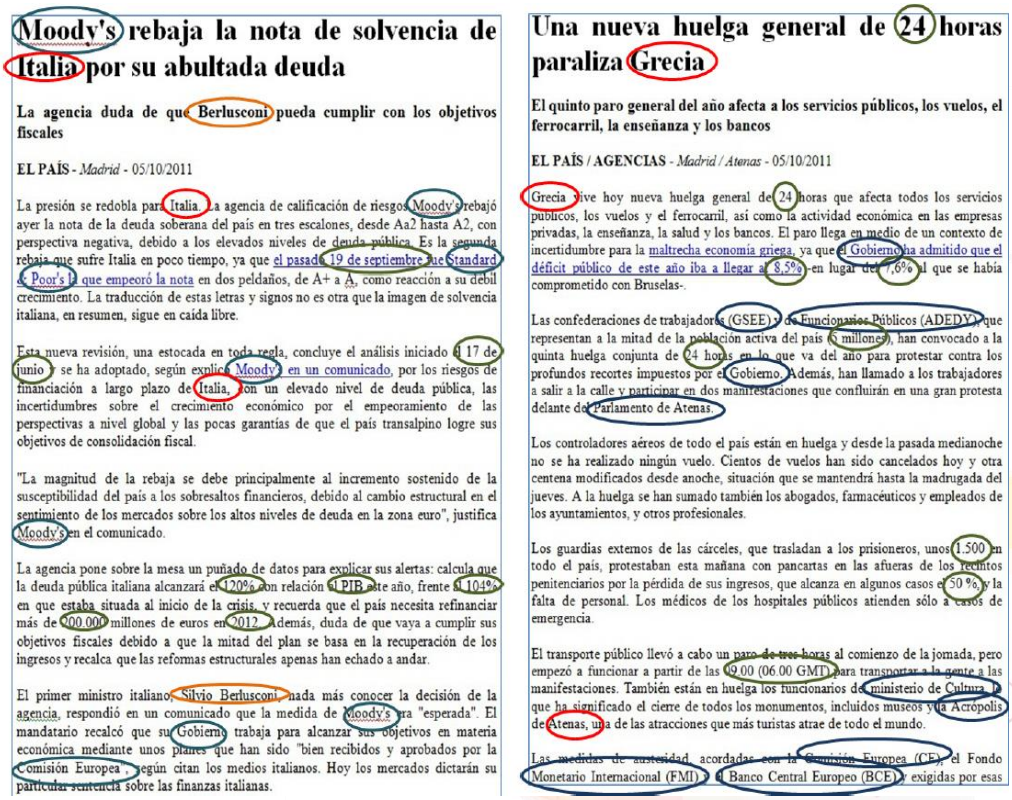

Moody's rebaja la nota de solvencia de Italia por su abultada deuda

La agencia duda de que Berlusconi pueda cumplir con los objetivos fiscales

EL PAÍS - *Madrid* - 05/10/2011

La presión se redobla para Italia. La agencia de calificación de riesgos Moody's rebajó ayer la nota de la deuda soberana del país en tres escalones, desde Aa2 hasta A2, con perspectiva negativa, debido a los elevados niveles de deuda pública. Es la segunda rebaja que sufre Italia en poco tiempo, ya que el pasado 19 de septiembre Standard & Poor's la que empeoró la nota en dos peldaños, de A+ a A, como reacción a su débil crecimiento. La traducción de estas letras y signos no es otra que la imagen de solvencia italiana, en resumen, sigue en caída libre.

Esta nueva revisión, una estocada en toda regla, concluye el análisis iniciado el 17 de junio y se ha adoptado, según explica Moody's en un comunicado, por los riesgos de financiación a largo plazo de Italia, con un elevado nivel de deuda pública, las incertidumbres sobre el crecimiento económico por el empeoramiento de las perspectivas a nivel global y las pocas garantías de que el país transalpino logre sus objetivos de consolidación fiscal.

"La magnitud de la rebaja se debe principalmente al incremento sostenido de la susceptibilidad del país a los sobresaltos financieros, debido al cambio estructural en el sentimiento de los mercados sobre los altos niveles de deuda en la zona euro", justifica Moody's en el comunicado.

La agencia pone sobre la mesa un puñado de datos para explicar sus alertas: calcula que la deuda pública italiana alcanzará el 120% con relación al PIB este año, frente al 104% en que estaba situada al inicio de la crisis, y recuerda que el país necesita refinanciar más de 200.000 millones de euros en 2012. Además, duda de que vaya a cumplir sus objetivos fiscales debido a que la mitad del plan se basa en la recuperación de los ingresos y recalca que las reformas estructurales apenas han echado a andar.

El primer ministro italiano, Silvio Berlusconi, nada más conocer la decisión de la agencia, respondió en un comunicado que la medida de Moody's era "esperada". El mandatario recalcó que su Gobierno trabaja para alcanzar sus objetivos en materia económica mediante unos planes que han sido "bien recibidos y aprobados por la Comisión Europea", según citan los medios italianos. Hoy los mercados dictarán su particular sentencia sobre las finanzas italianas.

Una nueva huelga general de 24 horas paraliza Grecia

El quinto paro general del año afecta a los servicios públicos, los vuelos, el ferrocarril, la enseñanza y los bancos

EL PAÍS / AGENCIAS - *Madrid / Atenas* - 05/10/2011

Grecia vive hoy nueva huelga general de 24 horas que afecta todos los servicios públicos, los vuelos y el ferrocarril, así como la actividad económica en las empresas privadas, la enseñanza, la salud y los bancos. El paro llega en medio de un contexto de incertidumbre para la maltrecha economía griega, ya que el Gobierno ha admitido que el déficit público de este año iba a llegar al 8,5% -en lugar del 7,6% al que se había comprometido con Bruselas-.

Las confederaciones de trabajadores (GSEE) y de Funcionarios Públicos (ADEDY), que representan a la mitad de la población activa del país (5 millones), han convocado a la quinta huelga conjunta de 24 horas en lo que va del año para protestar contra los profundos recortes impuestos por el Gobierno. Además, han llamado a los trabajadores a salir a la calle y participar en dos manifestaciones que confluirán en una gran protesta delante del Parlamento de Atenas.

Los controladores aéreos de todo el país están en huelga y desde la pasada medianoche no se ha realizado ningún vuelo. Cientos de vuelos han sido cancelados hoy y otra centena modificados desde anoche, situación que se mantendrá hasta la madrugada del jueves. A la huelga se han sumado también los abogados, farmacéuticos y empleados de los ayuntamientos, y otros profesionales.

Los guardias externos de las cárceles, que trasladan a los prisioneros, unos 1.500 en todo el país, protestaban esta mañana con pancartas en las afueras de los recintos penitenciarios por la pérdida de sus ingresos, que alcanza en algunos casos el 30 %, y la falta de personal. Los médicos de los hospitales públicos atienden sólo a casos de emergencia.

El transporte público llevó a cabo un paro de tres horas al comienzo de la jornada, pero empezó a funcionar a partir de las 09.00 (06.00 GMT) para transportar a la gente a las manifestaciones. También están en huelga los funcionarios del ministerio de Cultura, lo que ha significado el cierre de todos los monumentos, incluidos museos y la Acrópolis de Atenas, una de las atracciones que más turistas atrae de todo el mundo.

Las medidas de austeridad, acordadas con la Comisión Europea (CE), el Fondo Monetario Internacional (FMI) y el Banco Central Europeo (BCE) y exigidas por esas

Figura 3. Ejemplo de noticias con las ENs resaltadas.

Es habitual que las entidades contengan información acerca de los protagonistas del suceso o evento que se describe en la noticia, y también cuándo y dónde se produce. Se trata de unidades de texto muy informativas, especialmente en el caso particular de textos de noticias. Por ello, se puede pensar en tenerlas en cuenta de forma diferente al resto de palabras del contenido de las noticias.

2. Posibilidad de traducción

Cuando se manejan textos en varios idiomas puede ser necesario recurrir a herramientas de traducción automática para unificar el lenguaje y que todos los textos estén en un único idioma. O para traducir sólo las partes de texto que interesen entre los idiomas que interesen o cualquier otra opción de traducción posible.

Existen diferentes APIs para traducir en Python, una de las más conocidas es *Goslate: Free Google Translate API*[2], que permite realizar traducciones utilizando el servicio web de traducción de Google, de forma rápida, sencilla y gratuita. Sin embargo, Google ha actualizado su servicio de traducción para prevenir que programas de crawling o similares puedan acceder a su servicio. De esta forma Goslate no se ha actualizado para "saltarse" este mecanismo de prevención de Google. Por ello, como alternativa se puede utilizar la librería TextBlob[3], que permite procesar textos en Python, pudiendo realizar diferentes tareas, entre ellas la traducción automática.

¿Cómo usarlo?

1. Instalación

   Con el entorno virtual activo en el que se desee instalar, ejecutar

   ```
   pip install textblob
   ```

2. Uso.

   TextBlob permite no sólo traducir, sino también detectar el idioma de un texto. A continuación, se presenta un ejemplo:

```
from textblob import TextBlob

t = TextBlob("Hello World")

print('original language:  ', t.detect_language())
print('Spanish translation: ',t.translate(to='es'))

print('French translation: ',t.translate(to='fr'))
```

[2] https://pypi.python.org/pypi/goslate

[3] http://textblob.readthedocs.io/en/dev/index.html